

# 2025 年 MathorCup 大数据竞赛 B 题赛题解析

## 一、赛题整体背景与核心任务拆解

### 1.1 赛题本质

赛道 B 聚焦**物流售后理赔的风险管控与成本控制**，核心是通过历史运单数据建立规则与模型，**解决“风险标注”“赔付金额预测”“风险类型预测”三大任务**，最终为物流企业 提供“快速识别不合理诉求、精准预测赔付成本”的决策支持。其核心矛盾在于平衡“客户体验”与“企业成本”，明确的业务逻辑展开。

### 1.2 核心数据与字段意义

数据附件	内容说明	核心用途
附件 1	已完成谈赔的历史运单，含实际赔付金额( $P$ )、索赔金额 ( $C$ )、商品属性(类型/保价)、运输属性(超时时长/异常原因)、网点属性(发单量/理赔率)等	规则建立、模型训练(问题 1-3 的基础数据)
附件 2	待预测运单，缺失实际赔付金额( $P$ )，特征字段与附件 1 一致	结果预测(问题 2 需预测 $P$ ，问题 3 需预测风险类型)

## 二、数据预处理

### 2.1 数据列名规整与类型定义

**A-C 列、I 列、K-M 列、O-R 列(类别型):** 线路类型, 是否 c2c, 生鲜妥投, 寄件是否内部, 异常原因, 进线渠道, 妥投到进线时长, 商品类型, 新旧程度, 寄件 B/C, 进线人身份。

**D 列、J 列、N 列、Y 列(数值型):** 保价金额, 配送超时时长, 索赔金额, 实际赔付金额。

**E-H 列(高基数 ID 类):** 始发城市 ID, 目的城市 ID, 寄件人 id, 收件人 id。

**S-X 列(网点统计数值型):** 始发网点发单量, 始发网点万单理赔率, 始发网点赔付比例, 目的网点发单量, 目的网点万单理赔率, 目的网点赔付比例。

### 2.2 缺失值处理

异常值可能对模型有不良影响, 可做处理包括:

配送超时时长(J 列): 缺失值很可能代表“准时送达”, 可填充为 0。

异常原因(K 列): 缺失值代表“无汇报异常”, 可以创建一个新类别, 如“NoAbnormality”, 这本身就是一个有用的信息。

网点特征(S-X 列): 如果有缺失, 可能是新网点无历史数据, 可使用全局的中位数填充, 因为它对异常值不敏感。

### 2.3 异常值检测与平滑

重点检查: 保价金额(D)、索赔金额(N)和实际赔付金额(Y)。

方法: 使用**箱线图 (BoxPlot)** 识别离群点。对于那些远超正常范围的值 (例如, 索赔金额远大于保价金额数倍且商品并非贵重品), 可以采用**盖帽法**, 例如将所有超过 99.9% 分位数的值替换为 99.9% 分位数的值, 以减小极端个例对模型的负面影响。

### 2.4 数据标准化

标准化有助于**消除不同特征之间的量纲差异**, 使其对模型影响均衡。

### 三、问题 1：基于附件 1 的风险标注模型建立（规则制定任务）

#### 3.1 核心目标

通过“索赔差额 (D)”和“实际赔付金额 (P)”，将附件 1 运单划分为“合理诉求”“诉求偏高”“严重超额”三类，需同时满足：

(1) 硬约束：合理诉求占比 $\geq 85\%$ ，严重超额占比 $<3\%$ ；

(2) 业务逻辑：P 越高，D 的合理阈值越宽松；同类运单 D 分布需“密集”（方差小），不同类 D 密集度差异较显著。

#### 3.2 关键解题步骤（无监督规则制定，非机器学习）

##### 3.2.1 数据预处理：先算 D+清异常

(1) 第一步：计算索赔差额 D

严格按初赛文件公式：索赔差额 (D) = 实际赔付金额 (P) - 索赔金额 (C)。

关键解读：D 通常为负（客户索赔金额 C 普遍高于企业实际赔付 P），D 越接近 0（或为正），代表客户诉求与企业赔付标准越契合，合理性越强；D 负得越多，诉求越不合理。

(2) 第二步：清洗异常值与缺失值（易忽略异常值对规则的扭曲）

##### 3.2.2 探索性分析 (EDA)：验证业务规律（易跳过 EDA 直接定规则，导致规则脱离数据）

必须通过 EDA 揭示 P 与 D 的关联，为规则提供数据支撑，核心分析维度及细节如下表：

分析内容	操作方式	意义与预期结论
P-D 散点图	(1) 提取附件 1 中 P 和 D 列； (2) 横轴设为 P，纵轴设为 D； (3) 可按“商品类型”着色，例：Jewelry→红、Miscellaneous Goods→蓝； (4) 其他醒目颜色标注典型异常点。	验证“P 越高，D 阈值越松” (1) 相同颜色的点在 P 轴上应该多数集中在某个区间（同一商品类型的实际赔付金额集中） (2) 随 P 增大，D 的“合理分布区域”拓宽
D 的分层分布	(1) 按 P 分档（例：0~120、120~350、350~800、800~2000、	验证“同类 D 密集，不同类差异显著”

	2000+); (2) 每档绘制 D 的核密度图; (3) 标注“合理/超额”预期区间	(1) 合理诉求区域：核密度图峰度高，即密度高； (2) 严重超额区域：峰度低，即密度低
比例统计	(1) 计算全量 D 的 3%、85% 分位数； (2) 统计各分位数区间样本占比； (3) 对比硬约束（合理 $\geq 85\%$ 、超额 $< 3\%$ ）	初步判断阈值范围，避免方向偏差

### 3.2.3 规则制定（即风险标注模型）

核心逻辑：按 P 分层→每层内按 D 分位数定阈值（易一刀切定阈值，忽略 P 对 D 的影响），具体步骤如下：

(1) 分层：分层目标是确保每层 P 范围连续、样本量均匀，避免阈值失真，可选用 K-means 聚类和分位数分层。

#### (2) 每层 D 阈值确定

分层方法	优点	缺点	适用场景
K-means 聚类	自动识别 P 自然分布，客观性强	对初始中心敏感，需多次运行；P 分布不均时效果差	数据量大
分位数分层	操作简单，每层样本量均匀，无需调参	主观性强；可能割裂 P 自然分布	数据量中/小

结合方案参考：

方案 1：DBSCAN 聚类划分 P 场景+分位数回归法定动态阈值

方案 2：GMM 聚类划分风险粗类别+分层分位数法细化阈值

#### (3) 规则验证（易不验证直接应用，导致规则不符合业务）

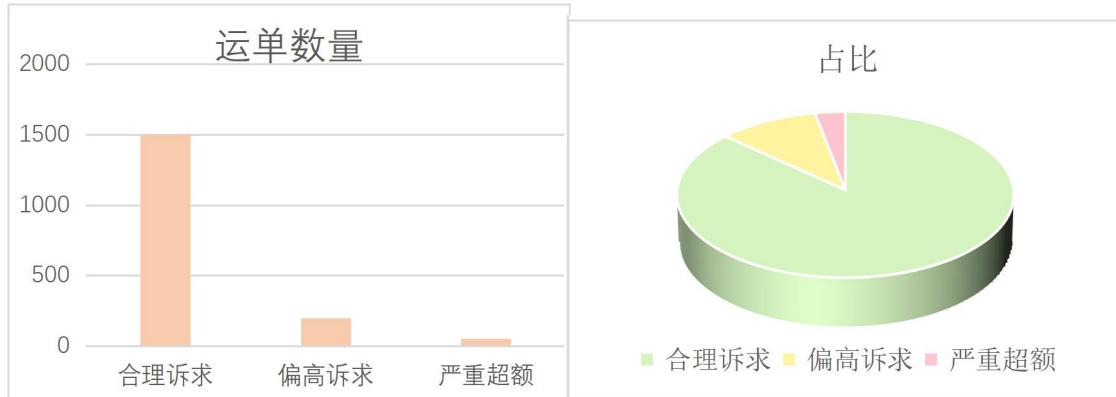
比例验证：全量样本三类占比需满足“合理 $\geq 85\%$ 、超额 $< 3\%$ ”，不满足则微调分位数；

密集度验证：计算同类 D 方差，需满足“合理方差  $<$  偏高方差  $<$  超额方差”。

### 3.2.4 输出附件 1 标注结果

生成“运单号-PCD-风险类型-所属 P 档”对照表，“风险类型”严格填写“合理诉求”“诉求偏高”“严重超额”，为后续问题 3 提供训练标签。

在论文中可进行图像可视化（可用柱状图、散点图等）和表格清晰化展示，如下为示意图和表：



风险标注	运单数量	占比
合理诉求		
偏高诉求		
严重超额		

## 四、问题 2：附件 2 实际赔付金额预测（回归模型任务）

### 4.1 核心目标

用附件 1 的运单特征建立回归模型，预测附件 2 的实际赔付金额，兼顾“预测精度”与“业务适配性”。

### 4.2 关键解题步骤

#### 4.2.1 特征工程（易特征泄露或冗余，导致模型泛化差）

**特征筛选：**不参考无价值特征（运单号、寄件人 ID），保留核心特征（商品类型、保价金额、异常原因等）；删除冗余特征。

**特征处理（按类型针对性处理）**

特征类型	示例特征	处理方法
分类特征（低基数）	商品类型（Fresh/Electronic）、异常原因（Damage/Lost）	独热编码（One-Hot）
分类特征（高基数）	始发城市 ID、目的城市 ID（类别>50）	目标编码：用该类别下 P 的均值替代类别
数值特征	保价金额、配送超时时长	异常值：IQR 法盖帽；标准化
二值特征	是否为 C2C（0/1）、是否生鲜妥投及时（0/1）	直接保留 0/1 编码

**衍生特征（提升模型解释力）**

基于业务场景构建新特征，例如：保价金额/索赔金额——反映客户保价与索赔的匹配度；始发网点理赔率+目的网点理赔率——反映链路风险；配送超时时长/预计配送时长——标准化超时程度。

#### 4.2.2 模型选择训练与预测评估

**（易盲目选复杂模型，忽略可解释性与效率）**

##### （1）回归任务选择

需可捕捉非线性、对大误差敏感、效率高的模型，可以使用模型包括：线性回归、随机森林回归、LightGBM 回归或 XGBoost。

##### （2）特征重要性分析

训练后，查看模型给出的特征重要性排序。我们预期索赔金额(N)以及我们构建的

寄件人\_历史平均索赔差额等用户画像特征是否名列前茅。既能验证我们思路的正确性，也能写入论文作为亮点。

### (3) 训练与评估

采用 5 折或 10 折交叉验证进行训练和评估，以获得模型性能的稳健估计并进行调参。

**评估指标：**可使用 **RMSE(均方根误差)**、**MAE(平均绝对误差)**、**R<sup>2</sup> (拟合优度/决定系数)**。

### (4) 预测

用全部处理好的附件 1 数据训练最终模型，然后对处理好的附件 2 数据进行预测。

## 五、问题 3：附件 2 风险标注预测与方法对比

### 5.1 核心目标

**预测任务：**用附件 1 的标注结果训练分类模型，直接预测附件 2 的风险类型（和问题 1 的三类标签一致），结果填入 Result 文件。

**分析任务：**处理“严重超额样本占比极低”的不平衡问题（如 SMOTE 过采样、调整类别权重），对比两种风险预测方法的优劣——“间接法”（用问题 2 的预测赔付金额+问题 1 的规则）和“直接法”（问题 3 分类模型直接预测风险）。

### 5.2 关键解题步骤

#### 5.2.1 数据准备（易特征泄露，导致模型虚假高性能）

**标签：**附件 1 的风险类型（0=合理诉求，1=诉求偏高，2=严重超额），确保标签与运单特征一一对应，可通过运单号关联；

**特征：**与问题 2 完全一致；

**数据划分：**附件 1 按 8:2 划分为训练集（80%）和验证集（20%），采用分层抽样（按风险类型比例抽样），确保验证集与训练集的风险类型分布一致，避免验证集无严重超额样本。

#### 5.2.2 处理“严重超额样本不均衡”

严重超额样本占比<3%，直接建模会导致模型偏向多数类，即合理诉求，漏判严重超额单（漏判会导致企业超额赔付，成本风险高），可从“数据层面”和“算法层面”双重处理：

处理层面	方法	优点	缺点
数据层面	SMOTE 过采样	(1) 避免随机过采样导致的过拟合; (2) 生成“真实”少数类样本，保留特征分布	(1) 若少数类样本本身有噪声，会放大噪声； (2) 对高维数据，插值样本可能与多数类重叠
数据层面	欠采样	操作简单，训练速度快	(1) 可能丢失有效信息 (2) 易导致模型欠拟合，泛化差
算法层面	类别权重调整	(1) 无需修改数据，直接在训练中惩罚少数类误分类 (2) 适配树模型，无额外计算成本	(1) 若少数类样本量极少，权重过高可能导致过拟合； (2) 对线性模型效果有限
混合策略 (推荐)	SMOTE + 类别权重	双重保障，显著提升少数类召回率，且降低过拟合风险	操作稍复杂，需调试 SMOTEk 值

### 5.2.3 分类模型训练与预测

#### (1) 模型选择

模型类型	优点	缺点
LightGBM 分类器	(1) 处理非线性能力强； (2) 支持类别权重和特征重要性； (3) 效率高	可解释性弱于逻辑回归
逻辑回归（多分类）	(1) 可解释性强； (2) 训练快	(1) 无法捕捉非线性； (2) 对不均衡数据敏感
随机森林分类器	(1) 抗过拟合； (2) 对异常值不敏感	(1) 高维数据效率低； (2) 少数类召回率低于 LightGBM

#### (2) 评估指标选择（不用准确率评估不均衡数据）

准确率（Accuracy）对不均衡数据无意义，需选择以下指标：宏 F1（Macro-F1）、  
少数类召回率（Recall\_超额）、加权 F1（Weighted-F1）。

### 5.2.4 方法对比：间接法 vs 直接法

需从“业务需求”“技术性能”“落地成本”三方面对比，结合业务逻辑给出建议：

### **路径一(回归+规则):**

优势：白盒逻辑，强可解释性。便于业务落地和规则迭代。

劣势：误差累积，问题 2 回归模型的预测误差会直接影响最终分类的准确性。

### **路径二(直接分类):**

优势：端到端优化，潜在性能更强，模型直接学习特征到风险等级的复杂映射，无需中间步骤。

劣势：黑盒模型，可解释性弱，且模型效果高度依赖问题 1 的标签质量。

## **六、竞赛技巧与论文撰写建议**

**先搭建基线：**先用一个基础模型快速跑通整个流程，得到一个初步结果。然后再逐步迭代，更换更强的模型、尝试更复杂的增强策略。

**可视化是王道：**在论文中大量使用图片。包括：数据增强效果对比、模型结构图、特征图可视化，以及各种评估指标可视化。**一定要把结果做的准确又清楚!!!**

结果文件格式：严格按照要求的格式输出。

## **七、MathorCup 大数据竞赛 B 题可参考相似赛题及优秀论文**

2023 年 MathorCup 高校数学建模挑战赛一大数据竞赛 B 题

电商零售商家需求预测及库存优化问题（附件给了赛题和 4 篇获奖优秀论文）